analysis

April 12, 2025

1 Análisis Farmacocinético Mono-Compartimental de Sunitinib en Ratones

1.1 Importar bibliotecas necesarias

```
[1]: from sunitinib_analysis.utils import solve_for_ka, SSR_2C_micro, solve_2C_micro import matplotlib.pyplot as plt import numpy as np import pandas as pd import random, math
```

1.2 Cargar y visualizar los datos

```
[2]: df = pd.read_csv('data.csv', index_col=0)
df
```

```
[2]:
                   Brain
                            Plasma
                                       Kidney
                                                     Liver
     TimePoint
                0.000000
     0.00
                          0.000000
                                     0.000000
                                                 0.00000
     0.08
                2.375455
                          1.253699
                                     7.725515
                                                 28.739378
     0.25
                2.428088
                          1.883693 17.777037
                                                 43.681615
     0.50
                2.473455
                          1.635242 22.042997
                                                 53.189255
     1.00
                3.671161
                          2.028957
                                    35.874868
                                                 80.544272
     2.00
                4.597385
                                    66.188478
                          2.850109
                                               158.306083
     4.00
                6.108580
                          3.384569
                                    64.424283
                                               119.348789
     6.00
                4.235917
                          2.608140
                                    53.622046
                                                 90.896761
     8.00
                2.888443
                          1.869260
                                    39.509340
                                                 71.328054
     12.00
                2.103540
                          1.188970
                                    19.110558
                                                 27.001372
```

1.3 Selección de columnas relevantes

```
[3]: df_plasma = df[['Plasma']].copy() df_plasma
```

```
[3]: Plasma
TimePoint
0.00 0.000000
0.08 1.253699
```

```
0.25
            1.883693
0.50
            1.635242
1.00
           2.028957
2.00
           2.850109
4.00
           3.384569
6.00
           2.608140
8.00
            1.869260
12.00
            1.188970
```

1.4 Determinar el máximo valor de concentración plasmática

```
[4]: max_plasma_idx = df_plasma["Plasma"].idxmax()
    max_plasma = df_plasma["Plasma"][max_plasma_idx]
    df_filtered = df_plasma.loc[max_plasma_idx:]
    df_filtered
```

[4]: Plasma
TimePoint
4.0 3.384569
6.0 2.608140
8.0 1.869260
12.0 1.188970

1.5 Cálculo de la constante de eliminación (k_e) y vida media (t½)

Fórmula utilizada:

$$\ln(C) = \ln(C_0) - k_e \cdot t$$

```
[5]: t_terminal = df_filtered.index.tolist()
    cp_terminal = df_filtered["Plasma"].tolist()
    lnCp_terminal = np.log(cp_terminal)
    slope, intercept = np.polyfit(t_terminal, lnCp_terminal, 1)

    ke = -slope
    t_half = np.log(2)/ke

    print(f'Constante de eliminación (k_e): {ke:.4f} h^-1')
    print(f'Vida media (t1/2): {t_half:.2f} h')
    print(f'Intersección con el eje (ln(CO)): {intercept:.4f}')
```

```
Constante de eliminación (k_e): 0.1318 h^-1 Vida media (t1/2): 5.26 h Intersección con el eje (ln(C0)): 1.7327
```

1.6 Estimación de la constante de absorción (k_a)

Ecuación a resolver:

$$\ln(x) = k_e(x-1)t_{max}$$

En código:

```
def f(x, ke, tmax):
        return math.log(x) - ke*(x - 1)*tmax
    def solve_for_ka(ke=0.13, tmax=4.0, x_lower=1.01, x_upper=20.0, tol=1e-7):
        fl = f(x_lower, ke, tmax)
        fu = f(x_upper, ke, tmax)
        if fl*fu > 0:
             raise ValueError("Sin cambio de signo en intervalo.")
        while (x_upper - x_lower) > tol:
             x_mid = 0.5*(x_lower + x_upper)
             fm = f(x_mid, ke, tmax)
             if fm == 0:
                 return x_mid * ke
             if fl*fm < 0:
                 x_{upper} = x_{mid}
                 fu = fm
             else:
                 x_lower = x_mid
                 fl = fm
        x_{final} = 0.5*(x_{lower} + x_{upper})
        return x final * ke
[6]: k_a_estimada = solve_for_ka(ke=ke, tmax=max_plasma_idx)
     print(f''k_e=\{ke:.3f\} h^-1, t_max=\{max_plasma_idx\} h, k_a \sim \{k_a_estimada:.4f\}_{\sqcup} 
      →h^-1")
```

 $k_e=0.132 h^-1$, $t_max=4.0 h$, $k_a \sim 0.4237 h^-1$

Cálculo del factor de concentración

```
[7]: factor = max_plasma / (math.exp(-ke * max_plasma_idx) - math.exp(-k_a_estimada_
     →* max_plasma_idx))
     print(f"Factor de concentración: {factor}")
```

Factor de concentración: 8.323754856250913

Modelo Monocompartimental con absorción y eliminación de primer orden

Ecuación del modelo:

$$C(t) = \text{factor} \cdot \left(e^{-k_e \cdot t} - e^{-k_a \cdot t}\right)$$

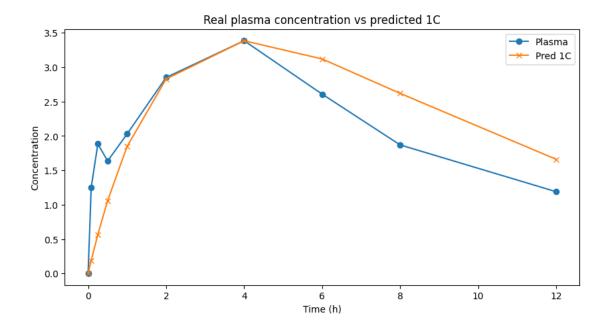
```
[8]: def C_1comp_1stOrder_abs_elim(t, factor=factor, ka=k_a_estimada, ke=ke):
         Ct = factor * (np.exp(-ke * t) - np.exp(-ka * t))
         return Ct
```

1.9 Predicciones y cálculo de errores

```
0.08
          1.253699 0.190130 1.063570 1.131181
0.25
          1.883693 0.566862 1.316831 1.734044
0.50
          1.635242 1.058368 0.576874 0.332784
1.00
          2.028957 1.847152 0.181806 0.033053
2.00
                   2.828155 0.021954 0.000482
          2.850109
4.00
          3.384569 3.384569 0.000000 0.000000
6.00
          2.608140 3.119462 -0.511322 0.261450
8.00
          1.869260 2.619034 -0.749773 0.562160
12.00
          1.188970 1.659886 -0.470916 0.221762
```

```
plasma_values = df_plasma["Plasma"].tolist()
pred_values = df_plasma["Pred 1C"].tolist()

plt.figure(figsize=(10, 5))
plt.plot(df_plasma.index, plasma_values, label='Plasma', marker='o')
plt.plot(df_plasma.index, pred_values, label='Pred 1C', marker='x')
plt.xlabel('Time (h)')
plt.ylabel('Concentration')
plt.title('Real plasma concentration vs predicted 1C')
plt.legend()
plt.show()
```



1.10 Cálculo de SSR (Suma de cuadrados residuales)

```
[11]: ssr_1c = df_plasma["error^2"].sum()
print(f"SSR: {ssr_1c:.4f}")
```

SSR: 4.2769

1.11 Cálculo del criterio de información de Akaike (AIC)

Fórmula utilizada:

$$AIC = n \cdot \ln\left(\frac{SSR}{n}\right) + 2p$$

Donde: - (n) = número de observaciones - (p) = número de parámetros (k_a, k_e, factor)

```
[12]: p = 3
n = len(df_plasma)-1

aic_1c = n*np.log(ssr_1c/n) + 2*p
print(f"AIC: {aic_1c:.4f}")
```

AIC: -0.6959

1.12 Resumen de resultados

- $\mathbf{k}_{\mathbf{e}}$ (constante de eliminación): 0.132
- k_a (constante de absorción): 0.4237
- Factor de concentración: 8.32
- **SSR**: 4.2769

• **AIC**: -0.6959

Esto permite evaluar el efecto del ketoconazol sobre la distribución de sunitinib en tejidos de ratones mediante comparación cuantitativa del modelo farmacocinético ajustado.

2 Análisis Farmacocinético Bi-Compartimental de Sunitinib en Ratones

2.1 Selección de columnas relevantes

```
[13]:
     df plasma
[13]:
                             Pred 1C
                    Plasma
                                           error
                                                   error<sup>2</sup>
      TimePoint
      0.00
                  0.000000
                            0.000000
                                       0.000000
                                                  0.000000
      0.08
                  1.253699
                            0.190130
                                       1.063570
                                                  1.131181
      0.25
                  1.883693
                            0.566862
                                       1.316831
                                                  1.734044
      0.50
                            1.058368
                  1.635242
                                      0.576874
                                                  0.332784
      1.00
                  2.028957
                            1.847152
                                       0.181806
                                                  0.033053
      2.00
                  2.850109
                            2.828155
                                       0.021954
                                                  0.000482
      4.00
                  3.384569
                            3.384569
                                       0.000000
                                                  0.000000
      6.00
                  2.608140
                            3.119462 -0.511322
                                                  0.261450
      8.00
                  1.869260
                            2.619034 -0.749773
                                                  0.562160
      12.00
                  1.188970
                            1.659886 -0.470916
                                                  0.221762
```

2.2 Datos observados

```
[14]: t_obs = df_plasma.index.tolist()[1:]
    cp_obs = df_plasma["Plasma"].tolist()[1:]
    n = len(t_obs)
```

2.3 Modelo Bicompartimental (microconstantes)

Las ecuaciones diferenciales del modelo bicompartimental son:

$$\begin{split} \frac{dX_g}{dt} &= -k_a \cdot X_g \\ \frac{dX_c}{dt} &= k_a X_g - k_{10} X_c - k_{12} X_c + k_{21} X_p \\ \frac{dX_p}{dt} &= k_{12} X_c - k_{21} X_p \end{split}$$

La concentración plasmática es:

$$C_p(t) = \frac{X_c(t)}{V_c}$$

2.4 Función de integración numérica (Euler)

```
def solve_2C_micro(ka, k10, k12, k21, Vc, times, dt=0.02):
    Xg, Xc, Xp = 1.0, 0.0, 0.0
    t_current = 0.0
    results, idx_times = [], 0
    max\_time = times[-1]
    while t_current <= max_time + 1e-9:</pre>
        while idx_times < len(times) and t_current >= times[idx_times]-1e-9:
            Cp = Xc / Vc
            results.append(Cp)
            idx\_times += 1
            if idx_times >= len(times):
                break
        dXg = -ka * Xg
        dXc = ka * Xg - k10 * Xc - k12 * Xc + k21 * Xp
        dXp = k12 * Xc - k21 * Xp
        Xg += dXg * dt
        Xc += dXc * dt
        Xp += dXp * dt
        t_current += dt
    return np.array(results)
```

2.5 Función para calcular SSR

```
def SSR_2C_micro(params, t_obs, cp_obs):
    ka, k10, k12, k21, Vc = params
    if any(p <= 0 for p in params):
        return 1e12

cp_pred = solve_2C_micro(ka, k10, k12, k21, Vc, t_obs)
    if np.any(cp_pred < 0) or len(cp_pred) != len(cp_obs):
        return 1e12

ssr = np.sum((cp_obs - cp_pred)**2)
    return ssr</pre>
```

2.6 Optimización de parámetros por búsqueda aleatoria

```
[15]: best_params, ssr_2c = None, 1e15
  random.seed(0)

  ssrs = []
  for _ in range(60000):
```

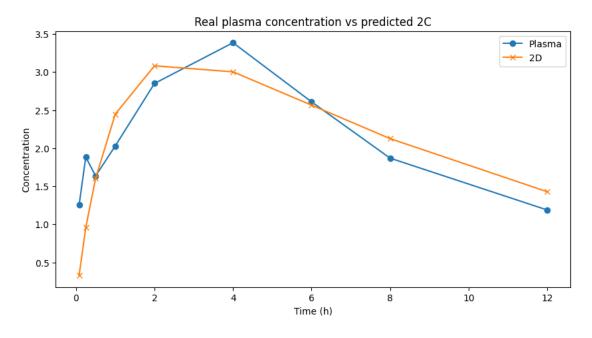
```
ka = 10**random.uniform(-2, 0.5)
k10 = 10**random.uniform(-2, 0.3)
k12 = 10**random.uniform(-2, 0.5)
k21 = 10**random.uniform(-2, 0.5)
Vc = 10**random.uniform(-1, 1.3)
params = (ka, k10, k12, k21, Vc)
ssr = SSR_2C_micro(params, t_obs, cp_obs)
ssrs.append(ssr)

if ssr < ssr_2c:
    ssr_2c, best_params = ssr, params

print("Mejor SSR encontrado:", ssr_2c)
print("Parámetros (ka, k10, k12, k21, Vc) =", best_params)</pre>
```

Mejor SSR encontrado: 2.2116222231494587
Parámetros (ka, k10, k12, k21, Vc) = (0.6466797633846326, 0.1573120040466821, 0.4492922916273097, 0.9008250884827278, 0.15134608984026762)

```
[16]: ka, k10, k12, k21, Vc = best_params
    cp_pred = solve_2C_micro(ka, k10, k12, k21, Vc, t_obs)
    plt.figure(figsize=(10, 5))
    plt.plot(t_obs, cp_obs, label='Plasma', marker='o')
    plt.plot(t_obs, cp_pred, label='2D', marker='x')
    plt.xlabel('Time (h)')
    plt.ylabel('Concentration')
    plt.title('Real plasma concentration vs predicted 2C')
    plt.legend()
    plt.show()
```



2.7 Criterio de información de Akaike (AIC)

La fórmula del AIC es:

$$AIC = n \cdot \ln\left(\frac{SSR}{n}\right) + 2p$$

donde (n) es el número de observaciones y (p) es el número de parámetros libres (5 en este caso).

```
[17]: p = 5
aic_2c = n * math.log(ssr_2c / n) + 2 * p
print("AIC (modelo bicompartimental) =", aic_2c)
```

AIC (modelo bicompartimental) = -2.631484641105997

2.8 Resumen de resultados

- Parámetros óptimos: (ka, k10, k12, k21, Vc) = (0.647, 0.157, 0.449, 0.9, 0.151)
- **SSR**: 2.21
- **AIC**: -2.631

Esto permite evaluar si el modelo bicompartimental mejora respecto al modelo monocompartimental para describir la farmacocinética del sunitinib en plasma.

[18]: SSR AIC

Modelo

Mono-Compartimental 4.276915 -0.695933 Bi-Compartimental 2.211622 -2.631485

3 Conclusiones del Análisis

El análisis comparativo entre los modelos farmacocinéticos indica que el modelo bicompartimental es más adecuado que el mono-compartimental, debido a que presenta un
valor de SSR más bajo (2.21 frente a 4.28), lo que refleja una mejor adaptación a los datos observados. Asimismo, el AIC es significativamente inferior (-2.63 frente a -0.70), reforzando
que el modelo bi-compartimental ofrece un mejor balance entre ajuste y simplicidad. Por tanto, se
recomienda el uso del modelo bi-compartimental para describir estos datos.